

基于 U-Net 的 FloodNet 灾害场景图像语义分割研究

23120899 周梓俊

摘要：洪水灾害场景中的道路、建筑、水体、植被和车辆等目标具有明显的空间关联和类别不平衡特征，仅依赖图像级判别难以满足灾后精细化评估的需要。为获得像素级场景理解结果，本文基于 FloodNet-Supervised_v1.0 数据集，研究标准 U-Net 在灾害航拍图像 10 类语义分割任务中的应用效果。实验构建编码器-解码器结构的 U-Net，并围绕学习率、输入尺寸、数据增强策略和损失函数开展逐步调参。最终模型采用学习率 1×10^{-4} 、输入尺寸 512×512 、强数据增强和 Dice Loss，在测试集上取得 Pixel Accuracy 84.47%、mIoU 52.52%、Dice Score 65.16%。实验结果表明，标准 U-Net 能够较稳定地提取灾害航拍图像中的大范围语义区域，但对受淹道路、小目标车辆以及水体与地物交界区域仍存在混淆。

关键词：语义分割，U-Net，FloodNet，灾害场景理解，Dice Loss

1 项目背景和意义

洪水灾害会对城市道路、建筑物、公共设施和自然地表面造成大范围影响。灾后快速获得受灾区域的空间分布信息，是应急救援、道路通行判断和损失评估的重要基础。随着无人机和航空遥感平台的发展，高分辨率灾害航拍图像能够在较短时间内覆盖受灾区域。然而，原始图像本身只提供视觉观测结果，若要进一步判断道路是否被淹没、建筑是否受损以及水体边界是否扩张，仍需要对图像中的不同地物进行像素级解析。

语义分割任务的目标是为图像中的每一个像素赋予类别标签。与图像分类相比，语义分割不仅判断图像中是否存在某类目标，还刻画该目标在空间上的具体范围；与目标检测相比，语义分割能够表达道路、水体、草地等非规则区域的连续边界。因此，在灾害场景理解中，语义分割更适合用于细粒度地物识别和受灾范围估计。本文选择 FloodNet 数据集作为研究对象，聚焦 U-Net 模型在灾害航拍图像语义分割任务中的表现，并通过系统调参分析影响模型性能的主要因素。

2 项目实现过程

2.1 数据集与任务定义

实验使用 FloodNet-Supervised_v1.0 数据集[1]。该数据集面向洪水灾害后的航拍场景理解，图像中同时包含受灾建筑、未受灾建筑、受淹道路、未受淹道路、水体、树木、车辆、泳池和草地等语义目标。与普通自然图像分割相比，该任务的难点在于灾害场景中水体与道路、草地、泥地之间存在明显外观混淆，同时小目标类别面积占比较低，容易在训练中被大面积类别主导。

本文将语义分割任务定义为一个逐像素多分类问题。设输入图像为 $I \in \mathbb{R}^{H \times W \times 3}$ ，其中 H 和 W 分别表示图像高度与宽度，3 表示 RGB 三个颜色通道。模型需要学习一个映射函数 f_θ ，将输入图像映射为每个像素在 10 个类别上的预测分数。该过程可表示为

$$Z = f_\theta(I), \quad Z \in \mathbb{R}^{H \times W \times C}. \quad (1)$$

式 (1) 中， θ 表示模型的可学习参数， C 表示类别数，在本文中 $C = 10$ ； Z 表示模型输出的 logits 张量， $Z_{h,w,c}$ 表示位于第 h 行、第 w 列的像素属于第 c 类的未归一化分数。最终预测类别通过在类别维度上取最大响应获得。

本文采用的类别编号包括 background、building-flooded、building-non-flooded、road-flooded、road-non-flooded、water、tree、vehicle、pool 和 grass。图1展示了数据样例。可以观察到，草地、水体和树木通常形成较大连续区域，而车辆、泳池以及部分道路区域面积较小。这种类别面积差异会影响损失函数和评价指标，因此后续实验中特别比较了交叉熵损失与 Dice Loss。




图 1: FloodNet 灾害航拍图像与语义标签样例

2.2 U-Net 模型结构

U-Net[2] 是一种典型的编码器-解码器语义分割网络，其核心思想是在压缩路径中提取高层语义特征，并在扩张路径中逐步恢复空间分辨率。灾害航拍图像中既存在建筑、水体等需要上下文判断的大区域，也存在车辆、道路边缘等依赖空间细节的小结构，因此单纯使用深层语义特征容易丢失边界信息。U-Net 通过跳跃连接将浅层空间细节与深层语义表示结合，使模型在恢复分割图时能够同时利用局部纹理和全局上下文。

本文实现的卷积块由两次卷积、Batch Normalization 和 ReLU 激活组成。对于第 l 层输入特征 $X^{(l)}$ ，基本变换可抽象为

$$X^{(l+1)} = \sigma \left(\text{BN} \left(W^{(l)} * X^{(l)} + b^{(l)} \right) \right). \quad (2)$$

式 (2) 中， $X^{(l)}$ 和 $X^{(l+1)}$ 分别表示第 l 层输入与输出特征图； $W^{(l)}$ 和 $b^{(l)}$ 为卷积核权重和偏置； $*$ 表示二维卷积； $\text{BN}(\cdot)$ 为 Batch Normalization； $\sigma(\cdot)$ 为 ReLU 激活函数。实际网络中连续使用两次该变换以增强局部特征表达。

在编码器部分，模型通过 MaxPool 操作逐级降低特征图分辨率，并增加通道数，使网络能够捕获更大范围的语义上下文。在解码器部分，模型通过转置卷积进行上采样，并与编码器中同尺度特征进行拼接。设解码器上采样后的特征为 $U^{(l)}$ ，编码器传递来的同尺度特征为 $S^{(l)}$ ，则跳跃连接后的融合特征可表示为

$$F^{(l)} = \text{Concat} \left(U^{(l)}, S^{(l)} \right). \quad (3)$$

式 (3) 中， $U^{(l)}$ 表示解码器第 l 个尺度上的上采样特征， $S^{(l)}$ 表示编码器同尺度特征， $\text{Concat}(\cdot)$ 表示通道维拼接， $F^{(l)}$ 为融合特征。该设计使解码器同时利用深层语义和浅层边缘纹理。

网络最后使用 1×1 卷积将特征通道数映射为类别数。对于每个像素位置 (h, w) ，模型输出 C 个类别的 logits，并通过 softmax 得到类别概率：

$$p_{h,w,c} = \frac{\exp(Z_{h,w,c})}{\sum_{k=1}^C \exp(Z_{h,w,k})}. \quad (4)$$

式 (4) 中， $p_{h,w,c}$ 表示第 h 行、第 w 列像素属于第 c 类的预测概率； $Z_{h,w,c}$ 为式 (1) 中对应类别的 logits； k 是类别求和下标，用于遍历所有 C 个类别。预测阶段选择概率最大的类别作为该像素的最终语义标签。

2.3 损失函数与评价指标

语义分割训练的本质是优化模型参数，使预测的类别分布尽可能接近真实标签分布。交叉熵损失是多类别分类中最常用的目标函数，它直接惩罚真实类别对应预测概率过低的情况。对于一个含有 N 个有效像素的训练批次，交叉熵损失定义为

$$\mathcal{L}_{CE} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log p_{i,c}. \quad (5)$$

式 (5) 中, N 为有效像素总数, i 为像素索引, C 为类别数, $y_{i,c}$ 是 one-hot 真实标签, 当第 i 个像素属于第 c 类时取 1, 否则取 0; $p_{i,c}$ 是第 i 个像素属于第 c 类的预测概率。该损失稳定, 但在类别面积不均衡时容易偏向大面积类别。

为减轻类别不均衡对训练的影响, 本文进一步比较 Dice Loss。Dice 系数直接度量预测区域与真实区域的重叠程度, 因此更关注分割区域的整体一致性。多类别 Dice Loss 写作

$$\mathcal{L}_{Dice} = 1 - \frac{1}{C} \sum_{c=1}^C \frac{2 \sum_{i=1}^N p_{i,c} y_{i,c} + \epsilon}{\sum_{i=1}^N p_{i,c} + \sum_{i=1}^N y_{i,c} + \epsilon}. \quad (6)$$

式 (6) 中, $\mathcal{L}_{Dice}$ 为多类别 Dice 损失, C 为类别数, i 为像素索引, $p_{i,c}$ 与 $y_{i,c}$ 分别表示预测概率和真实标签, ϵ 为避免分母为零的平滑项。与式 (5) 相比, 式 (6) 直接从区域重叠角度约束模型, 更适合小目标和类别不均衡场景。

模型评价采用 Pixel Accuracy、mIoU 和 Dice Score。Pixel Accuracy 衡量全部像素中预测正确的比例, 其定义为

$$PA = \frac{\sum_{c=1}^C TP_c}{\sum_{c=1}^C (TP_c + FN_c)}. \quad (7)$$

式 (7) 中, TP_c 表示第 c 类被正确预测为第 c 类的像素数, FN_c 表示真实为第 c 类但被预测为其他类别的像素数, C 表示类别数。该指标易于理解, 但当大面积类别占主导时可能高估模型对小类别的表现。

IoU 指标从区域重叠角度评价每一类的预测质量, mean IoU 则取各类别 IoU 的平均值:

$$IoU_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \quad mIoU = \frac{1}{C} \sum_{c=1}^C IoU_c. \quad (8)$$

式 (8) 中, IoU_c 表示第 c 类的交并比; TP_c 、 FP_c 和 FN_c 分别表示真正例、假正例和假负例像素数; $mIoU$ 表示对所有类别 IoU 求平均后的结果。由于式 (8) 同时考虑漏检和误检, 它比式 (7) 更能反映语义分割边界和小类别预测质量。

Dice Score 与 Dice Loss 相对应, 用于从重叠程度角度衡量预测结果, 其定义为

$$Dice_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}. \quad (9)$$

式 (9) 中, $Dice_c$ 表示第 c 类的 Dice 系数, TP_c 、 FP_c 和 FN_c 的含义与式 (8) 一致。Dice Score 数值越高, 表示预测区域与真实区域的重合程度越高。

2.4 实验平台与参数设置

实验在 AutoDL 云服务器上完成, 计算设备为 NVIDIA RTX 5090 GPU, 操作系统为 Linux, 深度学习框架为 PyTorch[3], 并启用 AMP 混合精度训练。输入图像统一缩放至指定尺寸, 图像采用双线性插值, 标签采用最近邻插值, 以避免标签类别值被插值成非整数。训练集数据增强包括无增强、随机水平翻转以及强增强三种设置, 其中强增强包含水平翻转、低概率垂直翻转以及亮度和对比度扰动; 所有空间变换均同时作用于图像和标签, 以保持像素对应关系。

调参采用逐步调参。第一阶段固定输入尺寸为 256、数据增强为 flip、损失函数为 CE, 比较学习率 0.01、0.001 和 0.0001。第二阶段固定最优学习率, 比较输入尺寸 256 与 512。第三阶段固定前两阶段最优设置, 比较 none、flip 和 strong 三种增强策略。第四阶段固定最优学习率、输入尺寸和增强策略, 比较 CE、Dice 和 CE+Dice 三种损失函数。调参阶段使用 30% 训练数据, 每组训练 10 epoch, 并以验证集 mIoU 作为模型选择指标。

3 实验结果及分析

3.1 参数调优结果

调参结果如表1和图2所示。在学习率实验中, 0.01 的最优验证 mIoU 仅为 0.2121, 且后期出现明显波动, 说明过大的学习率不利于稳定收敛。学习率 0.001 和 0.0001 的结果较接近, 但 0.0001 的验证 mIoU 略高, 达到 0.2632, 因此被选为后续实验设置。输入尺寸实验中, 512 的验证 mIoU 为 0.2684, 略高于 256 的 0.2632, 说明更高分辨率有助于保留道路、车辆和边界等空间细节。数据增强实验中, strong 增强获得 0.2728 的验证 mIoU, 高于 none 和 flip, 表明适度扰动能提高模型对航拍图像光照和

视角变化的鲁棒性。损失函数实验中，Dice Loss 的验证 mIoU 达到 0.2934，明显优于 CE 和 CE+Dice，这与 FloodNet 类别分布不均衡的特点一致。

表 1: 逐步调参结果

实验因素	比较设置	最优验证 mIoU	最终选择
学习率	0.01 / 0.001 / 0.0001	0.2632	0.0001
输入尺寸	256 / 512	0.2684	512
数据增强	none / flip / strong	0.2728	strong
损失函数	CE / Dice / CE+Dice	0.2934	Dice




图 2: 不同调参阶段的验证集 mIoU 对比

3.2 最终模型训练与测试结果

根据调参结果，最终模型采用学习率 1×10^{-4} 、输入尺寸 512×512 、strong 数据增强和 Dice Loss，在完整训练集上训练 30 epoch。训练曲线如图3所示。可以看到，训练损失整体下降，验证集 Pixel Accuracy、mIoU 和 Dice Score 总体上升，说明模型在训练过程中逐步学习到了灾害场景中的稳定语义结构。最佳验证结果出现在第 28 轮，此时验证集 Pixel Accuracy 为 0.8509，mIoU 为 0.5612，Dice Score 为 0.6842。第 30 轮验证 mIoU 略降至 0.5493，说明继续训练已经出现轻微波动，因此采用第 28 轮保存的最佳模型进行测试评估。




图 3: 最终模型训练损失与验证指标变化

最终模型在测试集上的总体指标见表2。测试集 Pixel Accuracy 为 0.8447，说明模型对多数像素具有较高分类正确率；mIoU 为 0.5252，Dice Score 为 0.6516。由于 mIoU 对每个类别赋予相同权重，类别面积较小或预测困难的类别会显著影响总体结果。若仅统计 1–9 类前景类别，foreground mIoU 提升至 0.5835，foreground Dice 达到 0.7240，说明 background 类的特殊分布对总体 mIoU 有一定拉低作用。

表 2: 最终模型测试集指标

统计范围	Pixel Accuracy	mIoU	Dice Score
全部 10 类	0.8447	0.5252	0.6516
前景 1–9 类	–	0.5835	0.7240

进一步分析分类结果可以发现, grass、road-non-flooded、tree、building-non-flooded 和 water 的 IoU 分别为 0.8248、0.7412、0.6974、0.6688 和 0.6173, 属于表现较好的类别。这些类别通常具有较大连续区域, 且纹理和颜色特征相对稳定。相比之下, road-flooded、vehicle 和 pool 的 IoU 分别为 0.3069、0.4614 和 0.4556, 说明模型对小目标和易混淆目标的识别仍然有限。特别是 road-flooded 往往同时具有道路结构和水体外观, 视觉特征介于两类之间, 因此容易被预测为 water 或 grass。

3.3 定性结果分析




图 4: 最终模型分割结果示例

图4展示了最终模型的定性结果。模型能够较好恢复草地、水体、树木、道路和建筑等大范围结构, 预测结果与真实标签在整体布局上较一致。与此同时, 边界区域仍存在一定程度的平滑化现象, 这与 U-Net 采用逐级下采样和上采样的结构有关: 深层特征有利于语义判别, 但空间分辨率降低后难以完全恢复精细边界。

4 总结与展望

本文围绕 FloodNet 灾害航拍图像语义分割任务, 实现并评估了标准 U-Net 模型。实验表明, 学习率、输入尺寸、数据增强和损失函数均会影响模型性能, 其中 Dice Loss 对类别不均衡场景具有较明显优势。最终模型在测试集上取得 Pixel Accuracy 84.47%、mIoU 52.52%、Dice Score 65.16%, 能够较好分割草地、道路、树木、水体和建筑等主要类别。与此同时, 模型在受淹道路、小目标车辆和复杂边界区域仍存在误分, 说明仅依赖标准 U-Net 的局部卷积和跳跃连接仍不足以完全解决灾害场景中的尺度变化和类别混淆问题。结合分类结果看, 车辆、泳池和受淹道路等类别仍是后续实验中需要重点关注的对象。

参考文献

- [1] Rahnemounfar M, Chowdhury T, Sarkar A, et al. FloodNet: A high resolution aerial imagery dataset for post flood scene understanding [J]. *IEEE Access*, 2021, 9: 89644–89654.
- [2] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation [C]. In: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Cham: Springer, 2015: 234–241.
- [3] Paszke A, Gross S, Massa F, et al. PyTorch: An imperative style, high-performance deep learning library [C]. In: *Advances in Neural Information Processing Systems*. 2019, 32: 8026–8037.